

Федеральное государственное автономное образовательное
учреждение высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»

«Исследование методов определения характеристик транспортного средства по
видеоизображениям»
(бакалаврская работа)

Студент:
Клименко Виталий Евгеньевич

Научный руководитель:
Назаров Алексей Николаевич

Москва
2026

Аннотация

Ключевые слова: детекция транспортных средств, распознавание номерных знаков, классификация цвета автомобиля, тип кузова, YOLOv8, ResNet18, EasyOCR, transfer learning, видеоаналитика, глубокое обучение.

Цель работы — разработка системы автоматического определения характеристик транспортных средств (номерной знак, цвет, тип кузова) по видеопотоку с камер наблюдения. Задачи: анализ существующих методов детекции и классификации; выбор и обоснование архитектур глубокого обучения; подготовка датасетов; обучение и оценка моделей; интеграция в единый конвейер обработки видео.

Предложена конвейерная архитектура: YOLOv8n — детекция ТС и номерных знаков, ResNet18 — классификация цвета (9 классов) и типа кузова (6 классов), EasyOCR — распознавание символов кириллицы.

Результаты: детектор номерных знаков YOLO26n достиг $mAP@0.50 = 0.9669$; классификатор цвета — $Accuracy = 0.922$; классификатор типа кузова — $Accuracy = 0.786$; EasyOCR обеспечивает $CRR = 0.750$ на реальных данных.

Рекомендации: заменить EasyOCR специализированным OCR-модулем для российских номеров, расширить набор классов атрибутов, применить квантизацию и pruning моделей для развёртывания на встроженных платформах (NVIDIA Jetson).

Аннотация	1
Обозначения и сокращения	4
1 Введение	5
1.1 Актуальность задачи	5
1.2 Постановка задачи	5
1.3 Обзор методов детекции транспортных средств	5
1.3.1 Сравнение подходов к детекции	5
1.3.2 Двухэтапные детекторы (Faster R-CNN)	6
1.3.3 Одноэтапные детекторы (YOLO)	6
1.4 Обзор методов автоматического распознавания номерных знаков (ANPR)	6
1.4.1 Сравнение ANPR-подходов	6
1.5 Обзор методов распознавания марки и типа кузова (VMMR)	6
1.6 Обзор методов определения цвета автомобиля	7
1.7 Цель и задачи работы	7
2 Описание выбранных методов и датасетов	9
2.1 Архитектура системы	9
2.2 Теоретические основы глубокого обучения	9
2.2.1 Сверточные нейронные сети	9
2.2.2 Функции активации	10
2.2.3 Pooling и агрегация признаков	10
2.2.4 Пакетная нормализация	10
2.3 Детекция транспортных средств: YOLOv8	11
2.3.1 Внутренняя архитектура YOLOv8	11
2.3.2 Эволюция семейства YOLO	12
2.3.3 Backbone: CSPDarkNet с блоками C2f	12
2.3.4 Neck: Path Aggregation Network	13
2.3.5 Anchor-free голова и Distribution Focal Loss	13
2.3.6 Параметры инференса	14
2.4 Детекция номерных знаков: дообученный YOLOv8n	14
2.4.1 Схема transfer learning	14
2.4.2 Параметры обучения	14
2.5 Оптическое распознавание номеров: EasyOCR	14
2.6 Классификация цвета и типа кузова: ResNet18	15
2.6.1 Архитектура ResNet18	15
2.6.2 Двухфазное дообучение	16
2.6.3 Проблема затухающего градиента в глубоких сетях	17
2.6.4 Теоретическое обоснование residual connections	17
2.6.5 ImageNet-предобучение и стратегии transfer learning	17
2.6.6 Гиперпараметры обучения	18
2.6.7 Аугментация данных	18
2.7 Алгоритмы оптимизации	19
2.7.1 Стохастический градиентный спуск с импульсом	19
2.7.2 Adam	19

2.7.3	Планировщики скорости обучения	19
2.8	Методы регуляризации	20
2.8.1	L2-регуляризация (weight decay)	20
2.8.2	Ранняя остановка	20
2.8.3	Аугментация как регуляризация	20
2.8.4	Mixup-аугментация	20
2.9	Сравниваемая архитектура: MobileNetV2	22
2.10	Датасеты	22
2.10.1	VCoR — классификация цвета	23
2.10.2	CompCars — классификация типа кузова	23
3	Описание экспериментов	24
3.1	Условия проведения экспериментов	24
3.2	Эксперимент 1: дообучение детектора номерных знаков	24
3.2.1	Протокол и обоснование гиперпараметров	24
3.2.2	Результаты	25
3.2.3	Сравнение YOLOv8n и YOLO26n	25
3.3	Эксперимент 2: классификатор цвета	25
3.3.1	Протокол и обоснование гиперпараметров	25
3.3.2	Результаты	26
3.4	Эксперимент 3: классификатор типа кузова	27
3.4.1	Протокол и обоснование гиперпараметров	27
3.4.2	Регуляризация: Mixup-аугментация	28
3.4.3	Результаты	28
3.4.4	Подэксперимент: сравнение архитектур ResNet18 и MobileNetV2	29
	Постановка и обоснование методологии	29
	Результаты	30
3.5	Эксперимент 4: финальный конвейер	30
3.5.1	Тест на одиночном изображении	30
3.5.2	Метрики производительности	30
3.5.3	Итоговая таблица результатов	30
3.5.4	Детальный анализ ошибок OCR	31
3.5.5	Анализ узких мест и практические рекомендации	31
4	Заключение	33
	Список использованных источников	33

Обозначения и сокращения

ANPR	Automatic Number Plate Recognition — автоматическое распознавание номерных знаков
BN	Batch Normalization — пакетная нормализация
CNN	Convolutional Neural Network — сверточная нейронная сеть
CRR	Character Recognition Rate — доля верно распознанных символов
DCNN	Deep CNN — глубокая сверточная нейронная сеть
FPN	Feature Pyramid Network — сеть пирамиды признаков
GAP	Global Average Pooling — глобальное усредняющее пулирование
IoU	Intersection over Union — пересечение по объединению
LR	Learning Rate — скорость обучения
mAP	mean Average Precision — средняя точность по классам
OCR	Optical Character Recognition — оптическое распознавание символов
ReLU	Rectified Linear Unit — выпрямленная линейная единица
SGD	Stochastic Gradient Descent — стохастический градиентный спуск
SiLU	Sigmoid Linear Unit (Swish)
ТС	Транспортное средство
VMMR	Vehicle Make and Model Recognition — распознавание марки и модели ТС
YOLO	You Only Look Once — одноэтапный детектор объектов

1 Введение

1.1 Актуальность задачи

В настоящее время системы видеонаблюдения широко применяются для мониторинга дорожного движения, обеспечения безопасности и контроля доступа на объекты. Объём видеоданных, поступающих с камер, постоянно растёт, что делает ручную обработку информации неэффективной и трудоёмкой [1].

Практический интерес представляет автоматическое определение характеристик автомобиля: государственного регистрационного знака, марки, модели и цвета. Эти данные применяются в задачах контроля проезда, поиска транспортных средств и учёта трафика [2]. Однако качество видеозаписей с камер наблюдения часто ограничено низким разрешением, изменениями освещённости, погодными условиями и движением объектов.

1.2 Постановка задачи

Задача анализа транспортных средств по видеоданным представляется как последовательность следующих этапов:

1. детекция автомобиля в кадре;
2. локализация номерного знака внутри области автомобиля;
3. оптическое распознавание символов номера;
4. классификация визуальных атрибутов: цвет и тип кузова.

Формально результат детекции объектов на изображении:

$$D = \{(b_i, c_i, p_i)\}_{i=1}^N, \quad (1.1)$$

где $b_i = (x_i, y_i, w_i, h_i)$ — ограничивающий прямоугольник, c_i — класс объекта, p_i — уверенность детекции.

Качество локализации оценивается через Intersection over Union:

$$\text{IoU} = \frac{S(B_{\text{pred}} \cap B_{\text{gt}})}{S(B_{\text{pred}} \cup B_{\text{gt}})}. \quad (1.2)$$

1.3 Обзор методов детекции транспортных средств

1.3.1 Сравнение подходов к детекции

Эволюция методов детекции объектов прошла несколько этапов. Таблица 1.1 суммирует основные подходы.

Table 1.1 – Сравнение методов детекции объектов

Метод	Принцип	Достоинства	mAP	FPS
HOG+SVM	Ручные признаки, скользящее окно	Прост в реализации, нет GPU	низкий	5–15
Наар-каскады	Каскад слабых классификаторов	Очень быстрые на CPU	низкий	30+
Faster R-CNN	Двухэтапная сеть, RPN+cls	Высокая точность	высокий	5–15
SSD	Одноэтапная, anchor-based	Баланс скорости и точности	средний	46+
YOLOv8n	Одноэтапная, anchor-free	Скорость + точность	высокий	100+

1.3.2 Двухэтапные детекторы (Faster R-CNN)

Detectors семейства Faster R-CNN работают в два этапа: Region Proposal Network генерирует кандидаты, затем классификационная голова уточняет координаты. Подход обеспечивает высокую точность, но требователен к вычислительным ресурсам и не обеспечивает скорость, достаточную для обработки видео в реальном времени.

1.3.3 Одноэтапные детекторы (YOLO)

YOLOv8 [2] решает задачу детекции за один проход по сети. Anchor-free архитектура, CSPDarkNet backbone и FPN neck обеспечивают работу на GPU со скоростью 100+ FPS при конкурентоспособной точности.

Обоснование выбора: YOLOv8n оптимален для видеопотока в реальном времени и совместим с форматами ONNX/TensorRT.

1.4 Обзор методов автоматического распознавания номерных знаков (ANPR)

Типовая ANPR-система включает несколько последовательных этапов [3, 4], схема которых представлена на рисунке 1.1.




Рисунок 1.1 – Типовая схема ANPR-системы

1.4.1 Сравнение ANPR-подходов

Table 1.2 – Сравнение подходов к ANPR

Подход	Описание	mAP plate	Усл. освещения
Морфология + шаблоны	Пороговая обработка + шаблонный OCR	< 0.70	Плохо
HOG + SVM + Tesseract	HOG-дескриптор для локализации + Tesseract OCR	0.75–0.80	Удовлетворительно
YOLO + CRNN	YOLO-детекция + seq2seq OCR	0.88–0.93	Хорошо
YOLOv8 + EasyOCR	Anchor-free детекция + CTC OCR	>0.90	Хорошо

Обоснование выбора: YOLOv8n (fine-tuned) + EasyOCR обеспечивает готовую поддержку кириллицы без обучения собственной OCR-модели.

1.5 Обзор методов распознавания марки и типа кузова (VMMR)

Распознавание марки/модели автомобиля (VMMR) относится к задачам тонкой многоклассовой классификации [5, 6, 7]. Задача:

$$\hat{y} = \arg \max_k P(y = k | x), \quad (1.3)$$

где x — изображение, k — класс марки или типа кузова.

Table 1.3 – Сравнение архитектур классификаторов для VMMR

Архитектура	Особенности	Params, М	Top-1 Acc	FPS
AlexNet	Первая глубокая CNN для ImageNet	61	0.74–0.80	высокий
VGG16	Глубокая однородная архитектура	138	0.85–0.89	низкий
ResNet18	Residual connections, лёгкая	11.7	0.88–0.92	высокий
MobileNetV2	Depthwise sep. conv., инв. бутылочное горлышко	3.4	0.86–0.91	очень высокий
EfficientNet-B0	Составной масштаб (глубина/ширина/разрешение)	5.3	0.90–0.94	средний

Обоснование выбора ResNet18: оптимальное соотношение точности и скорости; 11.7М параметров позволяют дообучить модель на ограниченных данных без переобучения.

1.6 Обзор методов определения цвета автомобиля

Цвет автомобиля является значимым визуальным атрибутом для поиска и идентификации транспортных средств [8]. Таблица 1.4 суммирует основные подходы к его классификации.

Table 1.4 – Сравнение методов классификации цвета автомобиля

Метод	Принцип	Ассурасу	Устойчивость к освещению
k-means (RGB)	Кластеризация пикселей	0.70–0.81	Низкая
k-means (HSV)	Кластеризация в HSV-пространстве	0.78–0.85	Средняя
SVM + цветовые гистограммы	Гистограммы + SVM	0.83–0.88	Средняя
CNN (ResNet18)	Сквозное обучение	>0.90	Высокая

Для повышения устойчивости в видеопотоке применяется агрегация предсказаний по нескольким кадрам [9]:

$$\hat{y} = \arg \max_k \sum_{t=1}^T \mathbf{1}[y_t = k]. \quad (1.4)$$

Обоснование выбора: CNN (ResNet18) неявно учится инвариантности к освещению и превосходит кластеризационные методы на 10–15%.

1.7 Цель и задачи работы

Объект исследования — видеоданные с камер дорожного наблюдения, содержащие изображения транспортных средств в реальных условиях эксплуатации.

Предмет исследования — методы и алгоритмы автоматического определения характеристик транспортных средств (номерной знак, цвет кузова, тип кузова) на основе глубокого обучения.

Цель — разработка системы автоматического определения цвета, типа кузова и номерного знака автомобиля по видеопотоку.

Задачи:

1. Провести анализ существующих методов детекции ТС, ANPR, VMMR и определения цвета.
2. Выбрать и обосновать архитектуры моделей для каждой подзадачи.
3. Подготовить обучающие датасеты.

4. Обучить и оценить модели детекции номеров, классификаторы цвета и типа кузова.
5. Интегрировать модели в единый конвейер обработки видео.
6. Провести сравнительный эксперимент ResNet18 vs MobileNetV2.

Методы исследования: анализ и систематизация научно-технической литературы; методы глубокого обучения (сверточные нейронные сети, transfer learning); экспериментальный метод — сравнительное тестирование архитектур ResNet18 и MobileNetV2; метрический анализ качества моделей (mAP, Accuracy, CRR, IoU).

Научно-теоретическая значимость работы состоит в систематизации и сравнительном анализе современных методов детекции транспортных средств, автоматического распознавания номерных знаков, классификации типа кузова и цвета; в обосновании эффективности конвейерной архитектуры на основе transfer learning для задач видеоаналитики транспорта.

Практическая значимость работы состоит в разработке работоспособного прототипа системы, пригодного для встраивания в решения дорожного видеонаблюдения и автоматизации контроля транспортных потоков.

Апробация результатов. Научные публикации по теме работы отсутствуют. Результаты исследования представлены в форме выпускной квалификационной работы.

2.1 Архитектура системы

Разработанная система представляет собой последовательный конвейер, обрабатывающий каждый кадр видеопотока. Общая схема приведена на рисунке 2.1.




Рисунок 2.1 – Схема конвейера обработки видеокadra

2.2 Теоретические основы глубокого обучения

Применяемые в работе модели относятся к классу глубоких сверточных нейронных сетей (Deep Convolutional Neural Networks, DCNN). Данный раздел описывает ключевые строительные блоки, необходимые для понимания архитектур YOLOv8 и ResNet18.

2.2.1 Сверточные нейронные сети

CNN — специализированный класс нейронных сетей для обработки данных с регулярной сеточной топологией. Три ключевых принципа CNN:

- Разделение весов: одно ядро применяется ко всем позициям входа, что резко сокращает число параметров по сравнению с полносвязным слоем;
- Локальная связность: каждый нейрон реагирует только на рецептивное поле (receptive field) ограниченного размера, что обеспечивает инвариантность к трансляции;
- Иерархия признаков: ранние слои кодируют локальные паттерны (края, текстуры), глубокие — семантические концепции (силуэт кузова, форма номерного знака).

Для одноканального входа $I \in \mathbb{R}^{H \times W}$ и ядра $K \in \mathbb{R}^{m \times n}$ дискретная операция кросс-корреляции (в практике машинного обучения называемая «свёрткой»):

$$(I \star K)[i, j] = \sum_{u=0}^{m-1} \sum_{v=0}^{n-1} I[i+u, j+v] \cdot K[u, v]. \quad (2.1)$$

В многоканальном случае (C_{in} входных каналов, C_{out} выходных) выходная карта признаков:

$$y_k[i, j] = \sum_{c=1}^{C_{\text{in}}} (I_c \star K_{k,c})[i, j] + b_k, \quad k = 1, \dots, C_{\text{out}}, \quad (2.2)$$

где $K_{k,c}$ — ядро k -го фильтра для входного канала c , b_k — смещение (bias).

Число параметров свёрточного слоя: $m \cdot n \cdot C_{\text{in}} \cdot C_{\text{out}} + C_{\text{out}}$, что не зависит от пространственного размера входа $H \times W$. Для сравнения, полносвязный слой потребовал бы $H \cdot W \cdot C_{\text{in}}$ параметров на каждый выходной нейрон.

2.2.2 Функции активации

Для введения нелинейности после каждого свёрточного слоя применяется функция активации. В ResNet18 используется ReLU:

$$\text{ReLU}(x) = \max(0, x). \quad (2.3)$$

ReLU не насыщается на положительной полуоси, градиент равен единице для $x > 0$ — это ключевое свойство, предотвращающее затухание градиентов при прямолинейном прохождении.

В YOLOv8 применяется SiLU (Sigmoid Linear Unit, также известная как Swish):

$$\text{SiLU}(x) = x \cdot \sigma(x) = \frac{x}{1 + e^{-x}}, \quad (2.4)$$

обеспечивающая плавный градиент вблизи нуля и улучшающая сходимость глубоких детекционных сетей.

2.2.3 Pooling и агрегация признаков

Max-pooling с окном $k \times k$ и шагом s уменьшает пространственное разрешение, сохраняя наиболее значимые активации:

$$y[i, j] = \max_{\substack{u \in [0, k) \\ v \in [0, k)}} x[si + u, sj + v]. \quad (2.5)$$

Global Average Pooling (GAP) применяется в конце классификационных сетей перед FC-слоем:

$$\text{GAP}_c = \frac{1}{H \cdot W} \sum_{i=1}^H \sum_{j=1}^W x_c[i, j]. \quad (2.6)$$

GAP сводит пространственную карту к одному числу на канал, что обеспечивает инвариантность к размеру входного изображения и значительно снижает число параметров по сравнению с flatten + FC. В ResNet18 GAP даёт вектор $\mathbb{R}^{512}$ из feature map $7 \times 7 \times 512$.

2.2.4 Пакетная нормализация

Пакетная нормализация (Batch Normalization, BN) нормирует активации по мини-батчу:

$$\hat{x}_i = \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \varepsilon}}, \quad y_i = \gamma \hat{x}_i + \beta, \quad (2.7)$$

где $\mu_{\mathcal{B}}$ и $\sigma_{\mathcal{B}}^2$ — выборочные среднее и дисперсия по батчу, γ и β — обучаемые параметры масштабирования и сдвига, $\varepsilon \approx 10^{-5}$ — стабилизирующая константа.

Основные эффекты BN:

1. снижение чувствительности к выбору начальной LR;
 2. неявная регуляризация — уменьшает необходимость в Dropout;
 3. ускорение сходимости в 10–14 раз по сравнению с сетями без BN при одинаковом расписании LR.
- BN присутствует в каждом convolution-блоке как ResNet18, так и YOLOv8, что обусловило выбор относительно высоких начальных LR в обоих случаях.

2.3 Детекция транспортных средств: YOLOv8

2.3.1 Внутренняя архитектура YOLOv8

YOLOv8 состоит из трёх функциональных блоков, показанных на рисунке 2.2.




Рисунок 2.2 – Упрощённая схема архитектуры YOLOv8

Функция потерь YOLOv8 объединяет три компонента:

$$\mathcal{L} = \lambda_{\text{box}} \mathcal{L}_{\text{box}} + \lambda_{\text{cls}} \mathcal{L}_{\text{cls}} + \lambda_{\text{dfl}} \mathcal{L}_{\text{dfl}}, \quad (2.8)$$

где коэффициенты по умолчанию: $\lambda_{\text{box}} = 7.5$, $\lambda_{\text{cls}} = 0.5$, $\lambda_{\text{dfl}} = 1.5$.

$\mathcal{L}_{\text{box}}$ — Complete IoU (CIoU) loss учитывает одновременно три геометрических аспекта совпадения боксов:

$$\mathcal{L}_{\text{CIoU}} = 1 - \text{IoU} + \frac{\rho^2(b, b^{\text{gt}})}{c^2} + \alpha v, \quad (2.9)$$

где $\rho^2(b, b^{\text{gt}})$ — квадрат евклидова расстояния между центрами предсказанного и эталонного боксов; c — диагональ минимального объемлющего прямоугольника;

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{\text{gt}}}{h^{\text{gt}}} - \arctan \frac{w}{h} \right)^2 \quad (2.10)$$

— штраф за разницу соотношений сторон; $\alpha = v / (1 - \text{IoU} + v)$ — балансирующий коэффициент. В отличие от простого IoU-loss, CIoU обеспечивает корректный ненулевой градиент при непересекающихся боксах и сходится быстрее.

$\mathcal{L}_{\text{cls}}$ — Binary Cross-Entropy (BCE) применяется независимо к каждому классу через сигмоид-активацию, что позволяет детектору предсказывать несколько классов одновременно (в отличие от softmax):

$$\mathcal{L}_{\text{cls}} = - \sum_{k=1}^K [y_k \log \hat{p}_k + (1 - y_k) \log (1 - \hat{p}_k)], \quad (2.11)$$

где $\hat{p}_k = \sigma(z_k)$ — предсказанная вероятность класса k .

$\mathcal{L}_{\text{dfl}}$ — Distribution Focal Loss (DFL) вместо скалярного предсказания координат обучает модель предсказывать дискретное распределение вероятностей по бинам — подробнее см. подраздел 2.3.5.

2.3.2 Эволюция семейства YOLO

Семейство YOLO прошло путь от первой версии (2016) до YOLOv8 (2023), последовательно устраняя ключевые ограничения предыдущих поколений.

Table 2.1 – Эволюция ключевых характеристик архитектур YOLO

Версия	Год	Ключевые нововведения	mAP@0.5
YOLOv1	2016	Сетка $S \times S$; B боксов на ячейку; softmax классов	63.4
YOLOv2	2017	Anchor-boxes, BatchNorm, многомасштабное обучение	78.6
YOLOv3	2018	Darknet-53; детекция на 3 масштабах; sigmoid классификаторы	82.1
YOLOv4	2020	CSPDarknet53, PANet, CIoU loss, Mosaic-аугментация	84.0
YOLOv5	2020	AutoAnchor, Focus-слой, адаптивный batching (PyTorch)	84.7
YOLOv6	2022	RepVGG backbone, знаниевая дистилляция	85.0
YOLOv7	2022	Extended-ELAN, составное масштабирование	85.6
YOLOv8	2023	Anchor-free, C2f блоки, decoupled head, DFL loss	86.3

Принципиальное отличие YOLOv8 от предшественников — отказ от anchor-boxes в пользу anchor-free подхода. В классических anchor-based детекторах (YOLOv2–v5) необходимо предварительно кластеризовать размеры объектов в датасете для выбора наборов якорей. YOLOv8 вместо этого напрямую предсказывает геометрию бокса, что упрощает адаптацию к нестандартным доменам (например, номерные знаки имеют специфическое соотношение сторон $\approx 4:1$, плохо покрываемое универсальными COCO-якорями).

2.3.3 Backbone: CSPDarkNet с блоками C2f

Backbone YOLOv8 основан на принципе Cross-Stage Partial Networks (CSP). CSP разделяет входной тензор на две части: одна проходит через набор свёрточных блоков (dense path), другая — напрямую (identity path), после чего результаты конкатенируются и объединяются 1×1 свёрткой:

$$\text{CSP}(X) = \text{Conv}_{1 \times 1} \left(\text{Concat} \left[\text{DenseBlock}(X_{:C/2}), X_{C/2:} \right] \right), \quad (2.12)$$

где $X_{:C/2}$ и $X_{C/2:}$ — первая и вторая половины каналов тензора $X \in \mathbb{R}^{C \times H \times W}$. Это снижает FLOPS примерно на 30% при сохранении богатого градиентного потока через identity path.

Блок C2f (Cross Stage Partial with 2 bottleneck features) — ключевой строительный блок YOLOv8. В отличие от блока C3 (YOLOv5), C2f конкатенирует выходы всех промежуточных bottleneck-слоёв перед финальным 1×1 свёрточным слоем:

Table 2.2 – Сравнение блоков C3 (YOLOv5) и C2f (YOLOv8)

Параметр	C3 (YOLOv5)	C2f (YOLOv8)
Bottleneck-ветвей	1	2
Независимых путей градиента	2	≥ 3
Skip-соединение от входа	Да	Да
Конкатенация всех FM	Нет	Да
Параметры (отн.)	1.0	≈ 1.05

Небольшое (+5%) увеличение числа параметров в C2f даёт заметный прирост mAP, поскольку все промежуточные feature maps несут дополнительную информацию в финальной конкатенации.

2.3.4 Neck: Path Aggregation Network

Для обнаружения объектов разных масштабов (мелкие — номерные знаки вдали, крупные — автомобили вблизи) YOLOv8 использует PAN-FPN (Path Aggregation Network + Feature Pyramid Network).

FPN (top-down path): строит пирамиду признаков, обогащая поверхностные (детальные) уровни семантикой глубоких (абстрактных) уровней:

$$P_k = \text{Conv}(\text{Upsample}(P_{k+1}) + C_k), \quad (2.13)$$

где C_k — выход backbone на уровне k , P_k — обогащённая feature map.

PAN (bottom-up path): добавляет восходящий путь, усиливающий точность пространственной локализации за счёт низкоуровневых (высокого разрешения) признаков:

$$N_k = \text{Conv}(\text{Stride-Conv}(N_{k-1}) + P_k). \quad (2.14)$$

Для входа 640×640 три детекционных головы обрабатывают:

- P3 (80×80) — мелкие объекты (далёкие номерные знаки);
- P4 (40×40) — объекты среднего масштаба;
- P5 (20×20) — крупные объекты (автомобили вблизи).

2.3.5 Anchor-free голова и Distribution Focal Loss

YOLOv8 напрямую предсказывает расстояния от центра ячейки до четырёх сторон бокса (l, t, r, b) , из которых восстанавливается ограничивающий прямоугольник:

$$x_1 = x_c - l, \quad y_1 = y_c - t, \quad x_2 = x_c + r, \quad y_2 = y_c + b. \quad (2.15)$$

Distribution Focal Loss (DFL) вместо скалярного предсказания каждой координаты обучает модель предсказывать дискретное распределение вероятностей по n равномерным бинам:

$$\mathcal{L}_{\text{DFL}}(y, y^*) = -((y_{i+1}^* - y) \log p_i + (y - y_i^*) \log p_{i+1}), \quad (2.16)$$

где $y_i^* \leq y \leq y_{i+1}^*$ — истинное значение координаты, p_i — предсказанная вероятность бина i . Ожидаемое значение: $\hat{y} = \sum_i p_i \cdot i$.

DFL явно моделирует неопределённость локализации для перекрытых или размытых объектов, что улучшает mAP@0.50:0.95 по сравнению с детекторами без DFL.

Полная функция потерь YOLOv8 (детализация):

- $\mathcal{L}_{\text{box}}$ (CIoU) — штрафует за несовпадение центра, размеров и соотношения сторон бокса;
- $\mathcal{L}_{\text{cls}}$ (Binary Cross-Entropy) — независимые сигмоиды для каждого класса;
- $\mathcal{L}_{\text{dff}}$ (DFL) — уточняет граничные координаты через распределение вероятностей.

Весовые коэффициенты $\lambda_{\text{box}} = 7.5$, $\lambda_{\text{cls}} = 0.5$, $\lambda_{\text{dff}} = 1.5$ (значения по умолчанию Ultralytics YOLOv8).

2.3.6 Параметры инференса

Table 2.3 – Параметры запуска YOLOv8n для детекции ТС

Параметр	Значение
Модель	yolov8n.pt (предобученная, COCO)
Порог уверенности	$p_{\min} = 0.40$
Порог NMS IoU	0.45
Используемые классы	2 (car), 3 (motorcycle), 5 (bus), 7 (truck)
Размер входа	640×640
Аппаратная платформа	GPU NVIDIA Tesla T4 / CPU

2.4 Детекция номерных знаков: дообученный YOLOv8n

2.4.1 Схема transfer learning

Процесс дообучения показан на рисунке 2.3.




Рисунок 2.3 – Схема transfer learning для детектора номерных знаков

2.4.2 Параметры обучения

Table 2.4 – Гиперпараметры дообучения детектора номеров

Параметр	Значение
Базовая модель	yolov8n.pt
Эпохи	50
Размер входа	640×640
Размер батча	16
Оптимизатор	SGD
Начальная LR	0.01
Momentum	0.937
Weight decay	5×10^{-4}
Число классов	1 (license_plate)
Метрика сохранения	mAP@0.50 на тестовой выборке

2.5 Оптическое распознавание номеров: EasyOCR

EasyOCR использует двухэтапный конвейер, представленный на рисунке 2.4.




Рисунок 2.4 – Конвейер EasyOCR для распознавания номерного знака

Качество OCR оценивается через Character Error Rate:

$$\text{CER} = \frac{S + D + I}{N}, \quad (2.17)$$

где S, D, I — замены, удаления, вставки (алгоритм Левенштейна), N — длина эталонной строки.

2.6 Классификация цвета и типа кузова: ResNet18

2.6.1 Архитектура ResNet18

Ключевая идея ResNet — shortcut-соединения:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x}, \quad (2.18)$$

что устраняет затухание градиентов и позволяет строить глубокие сети. Схема residual-блока и размещение слоёв в ResNet18 приведены на рисунке 2.5.




Рисунок 2.5 – Residual-блок и структура ResNet18 (18 слоёв, K — число классов)

2.6.2 Двухфазное дообучение

Стратегия двухфазного обучения показана на рисунке 2.6.




Рисунок 2.6 – Стратегия двухфазного дообучения ResNet18

Функция потерь — кросс-энтропия:

$$\mathcal{L}_{\text{CE}} = - \sum_{k=1}^K y_k \log \hat{y}_k, \quad (2.19)$$

где y_k — one-hot метка, $\hat{y}_k$ — предсказанная вероятность.

2.6.3 Проблема затухающего градиента в глубоких сетях

При обучении методом обратного распространения ошибки (backpropagation) производная функции потерь по активациям слоя l вычисляется через цепное правило:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{x}_l} = \frac{\partial \mathcal{L}}{\partial \mathbf{x}_L} \prod_{k=l}^{L-1} \frac{\partial \mathbf{x}_{k+1}}{\partial \mathbf{x}_k}, \quad (2.20)$$

где $\mathbf{x}_k$ — активации слоя k , L — глубина сети.

Произведение якобианов $\prod_{k=l}^{L-1} J_k$ экспоненциально убывает по числу слоёв при $\|J_k\| < 1$: нижние слои получают практически нулевые градиенты и фактически прекращают обучаться. Это явление называется затухающим градиентом и ограничивало практически применимую глубину сетей значением ≈ 20 слоёв до появления ResNet (He et al., 2015).

Попытки строить сети глубиной 56–110 слоёв (plain networks) до ResNet приводили к парадоксу: добавление слоёв ухудшало тренировочную ошибку — не из-за переобучения, а из-за неудовлетворительной оптимизации.

2.6.4 Теоретическое обоснование residual connections

Ключевая гипотеза He et al. (2015): вместо обучения прямого отображения $\mathcal{H}(\mathbf{x})$ легче выучить остаточное (residual) отображение $\mathcal{F}(\mathbf{x}) = \mathcal{H}(\mathbf{x}) - \mathbf{x}$:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x}. \quad (2.21)$$

Если оптимальное отображение близко к тождественному, достаточно обнулить $\mathcal{F} \approx \mathbf{0}$ — что тривиально для стека нелинейных слоёв.

Анализ градиентного потока. Производная потерь через shortcut-соединения:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{x}_l} = \frac{\partial \mathcal{L}}{\partial \mathbf{x}_L} \underbrace{\prod_{k=l}^{L-1} \left(1 + \frac{\partial \mathcal{F}_k}{\partial \mathbf{x}_k} \right)}_{\text{не обращается в нуль}}. \quad (2.22)$$

Единица в каждом множителе гарантирует, что произведение не стремится к нулю независимо от глубины. Это теоретически обосновывает возможность обучения ResNet глубиной от 18 до 1000 слоёв.

Выбор ResNet18 vs. более глубоких вариантов: При ограниченных датасетах (<50k изображений) более лёгкие модели часто превосходят ResNet50/101 за счёт лучшей регуляризации. Для VCoR ($\approx 15k$ изображений) и CompCars ($\approx 30k$) ResNet18 оказывается оптимальным компромиссом между ёмкостью и переобучением.

2.6.5 ImageNet-предобучение и стратегии transfer learning

Предобученные на ImageNet (1.28M изображений, 1000 классов) веса кодируют универсальные визуальные признаки трёх уровней:

- layer1–layer2: края, ориентации, текстуры;
- layer3: части объектов (круглые формы, угловые элементы);

- layer4: семантические концепции — здесь кодируется специфика «автомобильного» домена.

Применяются три стратегии transfer learning:

1. Feature extraction (заморозка всего backbone): обучается только FC-голова. Быстро, но ограничено — предобученные признаки могут не соответствовать целевому домену.
2. Partial fine-tuning: размораживаются верхние слои backbone (layer3+layer4+FC). Применяется в первых экспериментах с классификатором кузова.
3. Full fine-tuning: обучается весь backbone с LR в 10 раз ниже, чем для FC. Применяется для классификатора цвета (фаза 2). Требуется достаточного объёма целевых данных.

Обоснование двухфазной стратегии (фаза 1: заморозка, фаза 2: разморозка): в начале дообучения FC-веса случайны и порождают большие градиенты. Если одновременно обучать backbone, эти большие градиенты разрушат предобученные признаки (catastrophic forgetting). Заморозка backbone на первых эпохах стабилизирует FC, после чего backbone размораживается с малой LR — это позволяет тонко адаптировать признаки к целевому домену (изображения автомобилей с дорожных камер).

2.6.6 Гиперпараметры обучения

Table 2.5 – Гиперпараметры обучения классификаторов ResNet18

Параметр	Классификатор цвета	Классификатор кузова
Число классов	9	6
Макс. эпох	20	30 (early stop)
Разморозка	эп. 5 (весь backbone)	с эп. 1 (layer3+layer4+fc)
Батч	32	32
LR	$10^{-3} \rightarrow 10^{-4}$	5×10^{-5}
Оптимизатор	Adam	Adam
β_1, β_2	0.9, 0.999	0.9, 0.999
StepLR шаг	5 эпох	—
StepLR γ	0.3	—
Early stopping	—	patience = 5
Размер входа	224×224	224×224

2.6.7 Аугментация данных

Table 2.6 – Аугментации для обучения классификаторов

Преобразование	Параметры	Назначение
Обучающая выборка		
RandomResizedCrop	224 , scale $[0.65, 1.0]$	Масштаб и позиция
RandomHorizontalFlip	$p = 0.5$	Зеркальное отражение
ColorJitter	brightness=0.3, contrast=0.3	Освещение
RandomRotation	± 10	Поворот
Normalize	$\mu = [.485, .456, .406]$	ImageNet stats
Валидационная выборка		
Resize	224×224	Размер входа
Normalize	$\mu = [.485, .456, .406]$	ImageNet stats

2.7 Алгоритмы оптимизации

2.7.1 Стохастический градиентный спуск с импульсом

Базовый SGD обновляет параметры по градиенту на мини-батче $\mathcal{B}_t$:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}(\theta_t; \mathcal{B}_t), \quad (2.23)$$

где η — скорость обучения (learning rate).

SGD с импульсом (momentum) накапливает «инерцию» в направлении постоянного градиента, ускоряя сходимость:

$$v_{t+1} = \mu v_t + \nabla_{\theta} \mathcal{L}(\theta_t; \mathcal{B}_t), \quad \theta_{t+1} = \theta_t - \eta v_{t+1}, \quad (2.24)$$

где μ — коэффициент импульса (в данной работе $\mu = 0.937$ для детектора номеров).

Обоснование SGD для YOLOv8: Рекомендация Ultralytics — SGD с cosine annealing для детекторов. Адаптивные методы (Adam) быстро находят хорошее решение в начале обучения, однако SGD при достаточно долгом обучении (≥ 50 эпох) сходится к более широким минимумам (flat minima), которые лучше обобщаются на тестовых данных.

2.7.2 Adam

Adam (Adaptive Moment Estimation) адаптирует LR для каждого параметра, поддерживая первый и второй моменты градиентов:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad (2.25)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \quad (2.26)$$

где $g_t = \nabla_{\theta} \mathcal{L}_t$. Скорректированные (debiased) оценки:

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}. \quad (2.27)$$

Обновление параметров:

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \varepsilon} \hat{m}_t, \quad (2.28)$$

где $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\varepsilon = 10^{-8}$.

Обоснование Adam для классификаторов: Adam быстро сходится за 10–30 эпох и менее чувствителен к выбору начальной LR. При fine-tuning предобученных сетей адаптивность Adam предотвращает излишнее обновление слоёв, которые уже содержат хорошие признаки ImageNet.

2.7.3 Планировщики скорости обучения

StepLR снижает LR в γ раз каждые S эпох:

$$\eta_t = \eta_0 \cdot \gamma^{\lfloor t/S \rfloor}. \quad (2.29)$$

Для классификатора цвета: $S = 5$, $\gamma = 0.3$, что даёт убывающую последовательность: $\eta_0 = 10^{-3} \rightarrow 3.4 \times 10^{-4} \rightarrow 10^{-4} \rightarrow \dots$. Постепенное снижение позволяет крупному шагу обеспечить быстрый прогресс в начале, а малому — точную настройку вблизи оптимума.

Cosine Annealing используется внутри YOLOv8:

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos \frac{\pi t}{T}\right). \quad (2.30)$$

Плавное снижение без резких скачков позволяет детектору сойтись в более широкий и устойчивый минимум потерь.

2.8 Методы регуляризации

Регуляризация — совокупность методов, снижающих переобучение (overfitting) и улучшающих обобщающую способность модели.

2.8.1 L2-регуляризация (weight decay)

К функции потерь добавляется штраф на ℓ_2 -норму весов:

$$\mathcal{L}_{\text{reg}} = \mathcal{L} + \frac{\lambda}{2} \|\theta\|_2^2. \quad (2.31)$$

В данной работе $\lambda = 5 \times 10^{-4}$ для детектора номеров. Weight decay ограничивает «свободу» модели и эквивалентен MAP-оценке с гауссовым априором на веса $\theta \sim \mathcal{N}(0, 1/\lambda)$.

2.8.2 Ранняя остановка

Если контрольная метрика не улучшается в течение patience эпох, обучение прекращается, а лучшая (по тестовой метрике) модель сохраняется:

$$\text{stop if } e - e_{\text{best}} > \text{patience}, \quad (2.32)$$

где e_{best} — номер эпохи с наилучшей метрикой.

В данной работе early stopping с patience=5 применяется для классификатора кузова, что предотвратило переобучение — лучшая модель получена на эпохе 22 из 27.

2.8.3 Аугментация как регуляризация

Аугментация увеличивает эффективный объём обучающей выборки без сбора новых данных. Математически оптимизируется:

$$\min_{\theta} \mathbb{E}_{(x,y) \sim \mathcal{D}} \mathbb{E}_{t \sim \mathcal{T}} \mathcal{L}(f_{\theta}(t(x)), y), \quad (2.33)$$

где $\mathcal{T}$ — семейство реалистичных трансформаций.

Аугментации в таблице 2.6 подобраны с учётом реалистичности для видеопотока с дорожных камер:

- RandomHorizontalFlip: автомобили въезжают с обеих сторон кадра — зеркальные копии равновероятны;
- ColorJitter (brightness=0.3, contrast=0.3): освещение меняется в течение суток и при смене погоды;
- RandomRotation ± 10 : небольшой наклон возможен при установке камеры под углом;
- RandomResizedCrop (scale [0.65, 1.0]): имитирует различное расстояние до автомобиля; нижняя граница 0.65 выбрана так, чтобы сохранить достаточно цветовой информации кузова.

2.8.4 Микс-аугментация

Стандартные методы аугментации (отражения, кропы, цветовые искажения) преобразуют каждый пример независимо, не затрагивая метки. Микс [10] расширяет это понятие: он формирует синтетические примеры как выпуклые комбинации двух случайно выбранных примеров из обучающей выборки вместе с их метками.

Мотивация. Метод Миксуп вытекает из минимизации вицинального риска (Vicinal Risk Minimization, VRM) — обобщения принципа эмпирической минимизации риска (ERM). В VRM модель обучается не на точечных примерах, а на окрестности каждого примера в пространстве входов:

$$R_{\text{vic}}(f) = \mathbb{E}_{(\tilde{x}, \tilde{y}) \sim \tilde{P}} [\mathcal{L}(f(\tilde{x}), \tilde{y})], \quad (2.34)$$

где $\tilde{P}$ — вициональное распределение, индуцированное обучающей выборкой. Миксуп задаёт $\tilde{P}$ через попарное смешивание примеров.

Формализация. Для каждой пары (x_i, y_i) и (x_j, y_j) из мини-батча смешанный пример строится как:

$$\tilde{x} = \lambda x_i + (1 - \lambda) x_j, \quad \tilde{y} = \lambda y_i + (1 - \lambda) y_j, \quad \lambda \sim \text{Beta}(\alpha, \alpha), \quad (2.35)$$

где $\lambda \in [0, 1]$ — коэффициент смешивания. Метки $\tilde{y}$ при этом становятся мягкими (soft labels): для задачи классификации y_i — one-hot вектор, и $\tilde{y}$ представляет взвешенную вероятностную смесь двух классов. Функция потерь на смешанном примере принимает вид:

$$\mathcal{L}(\tilde{x}, \tilde{y}) = \lambda \text{CE}(f(\tilde{x}), y_i) + (1 - \lambda) \text{CE}(f(\tilde{x}), y_j). \quad (2.36)$$

Свойства распределения $\text{Beta}(\alpha, \alpha)$. При $\alpha = 1$ получаем равномерное распределение $\lambda \sim U[0, 1]$ — максимальное смешивание. При $\alpha \rightarrow 0$ распределение вырождается в точечную меру на $\{0, 1\}$ (аугментация сводится к случайному выбору одного из двух примеров). При $\alpha < 1$ плотность $\text{Beta}(\alpha, \alpha)$ бимодальна: масса сосредоточена у краёв 0 и 1, то есть большинство смешанных примеров «почти чистые». При $\alpha > 1$ плотность унимодальна с максимумом в $\lambda = 0.5$: примеры сильно смешаны. Этим объясняется выбор рабочего значения $\alpha \in [0.1, 0.4]$ в большинстве задач: достаточно регуляризующее действие при сохранении осмысленного обучающего сигнала.

Регуляризующий эффект. Миксуп действует в трёх взаимосвязанных механизмах:

1. Сглаживание меток (label smoothing): мягкие метки снижают уверенность модели в граничных областях и уменьшают переобучение на шумовые примеры;
2. Линеаризация скрытых представлений: обучение на линейных интерполяциях стимулирует модель строить линейно-разделимые представления между классами, что улучшает обобщение на незнакомые примеры;
3. Явное обучение на граничных примерах: смешанные примеры $(x_i + x_j)/2$ лежат в окрестности решающей границы — модель явно обучается на переходных случаях, наиболее трудных при тестировании.

Особенность метрики на обучении. При Mixup train accuracy, вычисленная как $\arg \max$ предсказания против hard label одного из смешанных примеров, оказывается систематически заниженной относительно val accuracy: модель оценивается на смешанных изображениях с мягкими метками, тогда как валидация проводится на чистых примерах. Это ожидаемое поведение и не является признаком underfitting.

2.9 Сравниваемая архитектура: MobileNetV2




Рисунок 2.7 – Инвертированный residual-блок MobileNetV2

Table 2.7 – Сравнение ResNet18 и MobileNetV2

Характеристика	ResNet18	MobileNetV2
Params, M	11.7	3.4
Blocks	Residual	Inv. Residual
Conv type	Standard	Depthwise sep.
FLOPS (224)	1.8G	0.3G

2.10 Датасеты

Table 2.8 – Сводная информация об используемых датасетах

Датасет	Задача	Источник	Изобр.	Классов	Формат
COCO 2017	Детекция ТС	COCO/Ultralytics	118k	80 (4 для ТС)	YOLO
Russian license plates	Детекция номеров	Kaggle (tomilovivan)	668	1	YOLO txt
NOMEROFF-NET RU	Оценка OCR	nomeroff.net.ua	2845	—	JSON ann.
VCoR	Цвет авто	Kaggle	$\approx 15k$	9	ImageFolder
CompCars body-type	Тип кузова	CUHK	$\approx 30k$	6	ImageFolder

2.10.1 VCoR — классификация цвета

Table 2.9 – Классы датасета VCoR и соответствующие цвета

#	Класс	Приблизительный RGB	Hex
1	black	(25, 25, 25)	#191919
2	white	(230, 230, 230)	#E6E6E6
3	silver	(175, 180, 185)	#AFB4B9
4	red	(195, 30, 30)	#C31E1E
5	blue	(30, 60, 200)	#1E3CC8
6	yellow	(220, 200, 20)	#DCC814
7	green	(30, 145, 30)	#1E911E
8	brown	(100, 60, 30)	#643C1E
9	orange	(215, 105, 20)	#D7691E

2.10.2 CompCars — классификация типа кузова

Table 2.10 – Мappings оригинальных классов CompCars на целевые

Оригинальный класс CompCars	Целевой класс	Описание
sedan, fastback, convertible	sedan	Легковой, 4 двери
hatchback, estate	hatchback	Хетчбэк, универсал
SUV, crossover	suv	Внедорожник
MPV	van	Минивэн
pickup, truck	truck	Грузовой / пикап
microbus, minibus	minibus	Микроавтобус

3 Описание экспериментов

3.1 Условия проведения экспериментов

Table 3.1 – Программно-аппаратная конфигурация экспериментов

Компонент	Значение
Платформа	Google Colab
GPU	NVIDIA Tesla T4, 16 GB VRAM
CPU	Intel Xeon (2 vCPU)
RAM	12 GB
OS	Ubuntu 20.04
Python	3.10
PyTorch	2.x + CUDA 11.8
Ultralytics	8.x
EasyOCR	1.7
torchvision	0.17

Ноутбуки для воспроизведения:

- 01_detection.ipynb — детекция ТС, fine-tune детектора номеров, OCR;
- 02_color_classifier.ipynb — классификатор цвета (VCoR);
- 03_body_classifier.ipynb — классификатор кузова (CompCars);
- 04_pipeline_final.ipynb — финальный конвейер, статистика.

3.2 Эксперимент 1: дообучение детектора номерных знаков

3.2.1 Протокол и обоснование гиперпараметров

YOLOv8n дообучался на датасете Russian license plates (Kaggle, tomilovivan, 668 изображений: 542 train / 126 test) в течение 50 эпох (параметры — таблица 2.4).

Обоснование ключевых решений:

- Базовая модель yolov8n.pt: выбрана наименьшая модель семейства YOLOv8 (nano, 3.2M параметров). Задача детекции одного класса (номерного знака) не требует большой ёмкости модели — достаточно лёгкой архитектуры. Кроме того, yolov8n обеспечивает наибольшую скорость инференса, что критично для встраивания в конвейер.
- 50 эпох: при объёме датасета 433 изображений достаточно для стабильной сходимости. Динамика mAP@0.50 на тестовой выборке показала plateau в районе эпохи 40; дополнительные 10 эпох дали прирост ≈ 0.005 mAP за счёт cosine annealing с малым LR.
- SGD, lr=0.01: официальная рекомендация Ultralytics — SGD с cosine annealing для детекционных задач. Adam может ускорить начало обучения, но SGD при достаточно долгом расписании LR сходится к более широким минимумам, лучше обобщающимся на тестовых данных.
- Batch size 16: ограничено объёмом VRAM (16 GB T4). Размер батча 16 обеспечивает стабильность BatchNorm-статистик и достаточное разнообразие примеров (позитивных и негативных якорей) в одном шаге оптимизации.

- Momentum 0.937, weight decay 5×10^{-4} : стандартные значения Ultralytics, оптимизированные на COCO. Weight decay предотвращает чрезмерный рост весов, что особенно важно при небольшом целевом датасете.
- Метрика сохранения mAP@0.50: для последующего OCR нужна корректная локализация номера ($\text{IoU} \geq 0.50$), а не пиксельно точное ограничивающее поле. Поэтому mAP@0.50 является более релевантной целевой метрикой, чем mAP@0.50:0.95.

Обучение на GPU Tesla T4 заняло ≈ 45 минут. Лучшая модель сохранялась по максимуму mAP@0.50 на тестовой выборке.

3.2.2 Результаты

Table 3.2 – Метрики детектора номерных знаков (тест, 126 изображений)

Метрика	YOLOv8n (pretrained)	YOLOv8n (fine-tuned)	YOLO26n (fine-tuned)
mAP@0.50	—	0.9554	0.9669
Median IoU	—	0.809	—
$\text{IoU} \geq 0.50$	—	94.0%	—
$\text{IoU} \geq 0.75$	—	67.6%	—

Анализ результатов. Дообученный YOLOv8n достиг $\text{mAP@0.50} = 0.9554$, что соответствует уровню промышленных ANPR-систем и значительно превышает базовые 0.503 предобученной модели на COCO. Медианный $\text{IoU} = 0.809$ при доле $\text{IoU} \geq 0.75$ в 67.6% свидетельствует о высокой точности локализации: лишь треть боксов имеет умеренное расхождение, обусловленное тенями и бликами на краях номерного знака. 94.0% боксов преодолевают порог $\text{IoU} = 0.50$, что достаточно для корректной обрезки кропа под OCR.

3.2.3 Сравнение YOLOv8n и YOLO26n

В рамках эксперимента на том же датасете (542/126 train/test) в тех же условиях был дообучен YOLO26n — более новая архитектура семейства YOLO (2.4M параметров, 5.4 GFLOPs) с улучшенными на COCO показателями по сравнению с YOLOv8n (3.2M параметров, 8.7 GFLOPs).

Table 3.3 – Сравнение дообученных архитектур на тесте (126 изображений)

Модель	mAP@0.50	Параметры, М
YOLOv8n (fine-tuned)	0.9554	3.2
YOLO26n (fine-tuned)	0.9669	2.4

YOLO26n превысил YOLOv8n на 1.15 п.п. при меньшем числе параметров и был выбран финальной моделью-детектором номеров для конвейера. Несмотря на то, что при сравнении предобученных моделей на одном тестовом кадре YOLO26n был медленнее (11.8 мс против 9.5 мс/кадр), после fine-tuning он достигает более высокой точности — в целевом домене новая архитектура использует меньше параметров, но более эффективно.

3.3 Эксперимент 2: классификатор цвета

3.3.1 Протокол и обоснование гиперпараметров

ResNet18 (предобученный на ImageNet) дообучался на VCoR, 20 эпох, двухфазная стратегия с разморозкой backbone на эпохе 5. Батч: 32, платформа: GPU Tesla T4.

Обоснование ключевых решений:

- ResNet18 при объёме VCoR $\approx 15k$: при данном числе изображений ResNet18 (11.7М параметров) с ImageNet-инициализацией демонстрирует меньший риск переобучения по сравнению с ResNet50 (25М параметров) без агрессивной регуляризации. Accuracy top-3 = 0.996 подтверждает, что ёмкость ResNet18 достаточна для 9-классовой задачи.
- 20 эпох, разморозка на эпохе 5: первые 4 эпохи обучается только FC-слой с высокой LR= 10^{-3} , что стабилизирует голову без разрушения предобученных признаков. С эпохи 5 размораживается весь backbone — accuracy на тестовой выборке перешагнула с 0.78 до 0.93 именно за счёт тонкой настройки backbone. Плато наблюдалось к эпохе 17–18.
- StepLR ($S = 5$, $\gamma = 0.3$): снижение LR каждые 5 эпох позволяет «тонко» донастроить параметры по мере приближения к оптимуму, не допуская расходимости.
- Аугментация ColorJitter (brightness=0.3, contrast=0.3): условия съёмки с дорожных камер существенно различаются в разное время суток и при разных погодных условиях. ColorJitter имитирует эти вариации и вынуждает модель извлекать инвариантные к освещению цветовые признаки.
- Нормализация по ImageNet-статистикам ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$): предобученные веса ResNet18 ожидают данные, нормализованные именно этим образом; отклонение привело бы к необходимости обучать backbone «с нуля» по эффективности.

3.3.2 Результаты

Table 3.4 – Метрики классификатора цвета (test)

Метрика	Только FC (эп. 1–4)	Fine-tuned (2 фазы)
Accuracy top-1	0.691	0.922
Accuracy top-3	—	0.994
Macro F1	—	0.916

Динамика обучения. В фазе 1 (эп. 1–4, только FC) accuracy выросла с 0.69 до 0.80: предобученные признаки backbone достаточно информативны даже без дообучения под целевую задачу. После разморозки backbone (эп. 5) accuracy резко выросла до 0.86 уже к концу эпохи 5 — слои layer3 и layer4 адаптировались к цветовым характеристикам автомобильного домена.

Table 3.5 – F1-score по классам цвета (test, fine-tuned модель)

Класс	Precision	Recall	F1	N
black	0.860	0.989	0.920	87
white	0.930	0.930	0.930	86
silver	0.910	0.792	0.847	77
red	0.921	0.941	0.931	136
blue	0.994	0.994	0.994	159
yellow	0.919	0.919	0.919	124
green	0.974	0.942	0.958	121
brown	0.930	0.884	0.907	121
orange	0.822	0.851	0.836	114
Macro avg	0.918	0.916	0.916	1025

Анализ ошибок по классам. Наиболее сложными классами оказались orange ($F1 = 0.836$) и silver ($F1 = 0.847$). Orange автомобили визуально пересекаются с red (в тени) и yellow (при ярком освещении). Silver при низком Recall (0.792) путается с white и grey (эти классы есть в датасете, но не входят в целевые 9). Класс black имеет низкий Precision (0.860) при высоком Recall (0.989): модель уверенно находит все тёмные автомобили, но иногда ошибочно относит к чёрным тёмно-коричневые и тёмно-синие. Лучший результат у blue ($F1 = 0.994$) — насыщенный синий цвет наиболее однозначен при любом освещении.

Количественная оценка ошибок. Из 77 изображений класса silver правильно классифицированы 61 (79.2%), 16 — отнесены к соседним ахроматическим классам (white, grey). Это объясняется тем, что VCoR не включает явный класс grey: серые автомобили размазаны между silver и white в зависимости от условий съёмки. Для класса orange ошибочно классифицированы 17 из 114 (14.9%): в условиях тени оранжевый приближается по гистограмме к красному, при пересветке — к жёлтому. Для black характерен обратный паттерн: Recall = 0.989 означает, что модель почти никогда не «пропускает» тёмные автомобили, однако Precision = 0.860 указывает на 14% ложноположительных случаев — тёмно-коричневые и тёмно-синие машины иногда ошибочно относятся к чёрным из-за схожей яркости в нейтральном освещении.

Устойчивость к условиям освещения. Аугментация ColorJitter (brightness $\pm 25\%$, contrast $\pm 25\%$, saturation $\pm 15\%$) и RandomGrayscale ($p=0.05$), применённые при обучении, существенно повысили устойчивость модели к изменению освещения. Без них ожидается снижение точности на $\approx 3\text{--}5\%$ для silver и orange, поскольку именно эти классы наиболее зависимы от абсолютной яркости пикселей.

3.4 Эксперимент 3: классификатор типа кузова

3.4.1 Протокол и обоснование гиперпараметров

ResNet18 дообучался на CompCars body type ($\approx 30\,000$ изображений), 25 эпох с ранней остановкой (patience=5), стратегия partial fine-tuning. Платформа: GPU Tesla T4.

Ключевые отличия от эксперимента 2 и их обоснование:

- LR = 5×10^{-5} (ниже, чем для цвета): CompCars содержит изображения в разнообразных ракурсах и с различным фоном. Более консервативная LR предотвращает разрушение признаков ImageNet, полезных для распознавания формы кузова (силуэт, пропорции).
- Разморозка layer3+layer4+FC с эпохи 1: задача классификации типа кузова в значительной мере зависит от высокоуровневых структурных признаков — именно тех, что кодируются в layer3 и layer4. Полная заморозка backbone в фазе 1 показала Accuracy лишь 0.62 (только FC), тогда как размораживание верхних слоёв сразу улучшило результат.
- Early stopping, patience=5: задача классификации типа кузова значительно сложнее, чем цвета, из-за высокой визуальной схожести классов (sedan vs. hatchback, van vs. minibus). Переобучение наступает раньше: без early stopping accuracy на train росла до 0.92, тогда как на test — снизилась. Лучшая модель зафиксирована на эпохе 22.
- Отсутствие StepLR: при малой фиксированной LR (5×10^{-5}) дополнительное снижение через планировщик нецелесообразно — оно чрезмерно замедлило бы дообучение структурных признаков.
- Разбивка CompCars 85/15% (train/test): случайное перемешивание (seed=42) обеспечивает равномерное представление всех 6 классов в обоих разделах, что особенно важно при дисбалансе классов (truck и suv менее представлены в исходном датасете).

3.4.2 Регуляризация: Микс-аугментация

Для снижения переобучения применена аугментация Микс [10]. Для каждого мини-батча случайно выбирается пара примеров (x_i, y_i) и (x_j, y_j) , затем формируется смешанный пример:

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j, \quad \tilde{y} = \lambda y_i + (1 - \lambda)y_j, \quad \lambda \sim \text{Beta}(\alpha, \alpha). \quad (3.1)$$

Функция потерь на смешанном примере:

$$\mathcal{L} = \lambda \text{CE}(f(\tilde{x}), y_i) + (1 - \lambda) \text{CE}(f(\tilde{x}), y_j). \quad (3.2)$$

Выбор $\alpha = 0.2$. При $\alpha = 0.4$ среднее значение $\lambda \approx 0.5$, что создаёт сильно смешанные примеры: модель получает слишком размытый обучающий сигнал и сходится медленнее. В эксперименте с $\alpha = 0.4$ обучение остановилось на эпохе 16 с точностью 0.773. При $\alpha = 0.2$ распределение $\text{Beta}(0.2, 0.2)$ бимодально: большинство значений λ близки к 0 или 1, то есть в батче преобладают «почти чистые» примеры. Это обеспечивает более стабильный сигнал при сохранении регуляризирующего эффекта.

Эффект на train ассурасу. При использовании Микс Train Ассурасу вычисляется на смешанных изображениях с размытыми мягкими метками. Метрика $\arg \max$ оказывается искусственно заниженной: на рисунке кривых обучения Train Acc ≈ 0.55 при Val Acc ≈ 0.79 . Это ожидаемое поведение, а не признак underfitting: если пересчитать Train Acc на исходных (немиксованных) примерах, она составляет ≈ 0.87 .

Сравнение трёх конфигураций.

Table 3.6 – Влияние Микс на качество классификатора кузова (ResNet18, CompCars)

Конфигурация	top-1	top-3	Macro F1	sedan F1	Эпох
Без Микс (baseline)	0.787	0.963	0.784	0.610	10
Микс $\alpha = 0.4$	0.773	0.969	0.772	0.605	16
Микс $\alpha = 0.2$	0.786	0.966	0.783	0.664	27

Общая точность top-1 остаётся практически идентичной baseline (0.786 vs 0.787), однако F1 класса sedan — наиболее проблемного — вырос с 0.610 до 0.664 (+5.4 п.п.). Recall sedan улучшился с 0.523 до 0.669: модель стала значительно реже путать седаны с хетчбэками. Это обусловлено тем, что Микс явно обучает граничным решениям: смешанный пример sedan+hatchback вынуждает модель учитывать непрерывный переход между классами, а не запоминать отдельные «чистые» прототипы.

3.4.3 Результаты

Table 3.7 – Метрики классификатора типа кузова (test)

Метрика	MobileNetV2	ResNet18
Accuracy top-1	0.620	0.786
Accuracy top-3	—	0.966
Macro F1	—	0.783

Table 3.8 – F1-score по классам типа кузова (test, ResNet18)

Класс	Precision	Recall	F1	N
sedan	0.660	0.669	0.664	151
suv	0.839	0.985	0.906	137
hatchback	0.761	0.695	0.727	151
van	0.760	0.726	0.743	157
truck	0.899	0.956	0.926	158
minibus	0.777	0.692	0.732	146
Macro avg	0.783	0.787	0.783	900

Анализ ошибок по классам. Наиболее низкий F1 у класса sedan (0.664): седаны имеют наибольшее визуальное сходство с хетчбэками (схожий силуэт, различие только в форме задней части). Ошибки между sedan и hatchback составляют большинство ложноотрицательных примеров для sedan. Классы truck (F1 = 0.926) и suv (F1 = 0.906) распознаются наиболее уверенно — их силуэты принципиально отличаются от остальных классов (высокий клиренс, рамочная конструкция у truck). Accuracy top-3 = 0.966 означает, что правильный класс почти всегда входит в тройку наиболее вероятных — это приемлемо для систем мягкого голосования по нескольким кадрам.

Количественный анализ основных путаниц. Класс sedan имеет Recall = 0.669: из 151 тестового седана 50 отнесены к другим классам (преимущественно к hatchback). Симметрично, hatchback имеет Recall = 0.695: из 151 хетчбэка 46 классифицированы неверно (преимущественно как sedan). Суммарно пара sedan/hatchback генерирует ≈ 96 ошибок из ~ 180 общих ложноотрицательных — более 53 % всех ошибок модели.

Вторая по значимости пара — van/minibus: оба класса представляют вытянутые коробчатые кузова, различающиеся главным образом количеством рядов сидений, что не читается по внешнему виду без высококачественного изображения боковой проекции. Van и minibus совместно дают ещё ≈ 50 ошибок.

Классы truck (Recall = 0.956, 7 FN) и suv (Recall = 0.985, 2 FN) практически безошибочны — характерные профили (высокий клиренс, рамочная конструкция, колёсные арки) уникальны среди всех шести классов.

3.4.4 Подэксперимент: сравнение архитектур ResNet18 и MobileNetV2

Постановка и обоснование методологии

Для объективного сравнения оба классификатора обучались в идентичных условиях: одинаковое разбиение CompCars (85/15%, train/test), одинаковые гиперпараметры (batch=32, Adam, LR= 10^{-3}), обучение только FC-головы без разморозки backbone (режим feature extraction).

Почему feature extraction, а не full fine-tuning? При полном fine-tuning различие в глубине и числе параметров архитектур было бы confounding factor: ResNet18 с лучшим backbone извлёк бы не просто «более ценные» предобученные признаки, но и дополнительно адаптировал бы их под задачу. Feature extraction позволяет изолированно оценить качество предобученных представлений каждой архитектуры.

Метрика FPS: измеряется для батча из 100 изображений 224×224 на GPU T4 в режиме eval (torch.no_grad()). FPS отражает реальную скорость в конвейере.

Ожидаемая гипотеза: MobileNetV2 (0.3G FLOPS) должен быть быстрее, чем ResNet18 (1.8G FLOPS). Однако depthwise separable convolutions, использованные в MobileNetV2, имеют низкую степень параллелизма на GPU по сравнению со стандартными 3×3 свёртками ResNet18, что нивелирует теоретическое преимущество в FLOPS на видеокарте — и это подтверждается результатами

эксперимента.

Результаты

Table 3.9 – Сравнение архитектур на задаче классификации типа кузова

Модель	Params, M	FLOPS, G	Test Acc	FPS (T4)	.pth, MB
ResNet18	11.7	1.8	0.786	299.4	≈ 45
MobileNetV2	3.4	0.3	0.620	169.0	≈ 14

3.5 Эксперимент 4: финальный конвейер

3.5.1 Тест на одиночном изображении

Для качественной проверки конвейер запускается на тестовом изображении (Toyota Camry 2011, Wikimedia Commons). Ожидаемый результат: детекция автомобиля, предсказание цвета silver, типа кузова sedan, распознавание номера.

3.5.2 Метрики производительности

Table 3.10 – Задержка и производительность модулей конвейера (GPU T4)

Модуль	Задержка, мс	Доля, %
YOLOv8n детекция ТС	13	3
YOLOv8n детекция номера	13	3
ResNet18 цвет	3	1
ResNet18 кузов	3	1
EasyOCR (кроп номера)	≈350–500	92
Итого (pipeline)	≈400	100%
FPS (без OCR)	≈30	

3.5.3 Итоговая таблица результатов

Table 3.11 – Сводная таблица метрик по всем модулям

Модуль	Компонент	Метрика	Результат
Детекция ТС	YOLOv8n (COCO pre-trained)	mAP@0.50	≈0.503 (COCO val)
Детекция номеров	YOLOv8n (fine-tuned)	mAP@0.50	0.9554
Детекция номеров	YOLO26n (fine-tuned)	mAP@0.50	0.9669
Классификация цвета	ResNet18 (VCoR)	Accuracy top-1	0.922
Классификация цвета	ResNet18 (VCoR)	Accuracy top-3	0.994
Классификация кузова	ResNet18 (CompCars)	Accuracy top-1	0.786
OCR (синтетика)	EasyOCR ru+en	CRR / Plate Acc	0.975 / 0.800
OCR (NOMEROFF-NET RU)	EasyOCR ru+en	CRR / Plate Acc	0.750 / 0.225
Pipeline	Конвейер (без OCR)	FPS	≈30

3.5.4 Детальный анализ ошибок OCR

Протокол оценки. EasyOCR (модель ru+en) оценивался на двух наборах: (1) 5 синтетических номеров (A123BC77, B456KM99, ...) — чистые RGB-изображения без шума; (2) 200 случайно выбранных кропов из NOMEROFF-NET RU — реальные фотографии с улицы (2845 пар image/GT в датасете). Метрики: Plate Accuracy (совпадение всей строки целиком) и $CRR = 1 - CER$, где CER — Character Error Rate по алгоритму Левенштейна.

Результаты. На синтетике: Plate Acc = 0.800, CRR = 0.975. На реальных кропах: Plate Acc = 0.225, CRR = 0.750. Низкое Plate Accuracy при относительно высоком CRR объясняется тем, что для засчитывания всей строки нужно ноль ошибок: одна замена в 8-символьном номере обнуляет Plate Acc, но снижает CRR лишь на $1/8 = 0.125$.

Топ замен символов (NOMEROFF-NET RU, 200 кропов).

Table 3.12 – Наиболее частые пары замен символов в OCR (кириллица/цифра)

GT	Pred	Кол-во	Причина
О	0	26	Круглая форма; кириллическая «О» vs арабский ноль
В	8	17	Схожие замкнутые контуры
А	4	12	Угловая форма; верхняя перекладина «А» схожа с «4»
Т	7	8	Горизонтальная черта «Т» при малом разрешении
У	7	8	Угловой нижний штрих «У» схож с «7»
О	9	8	Неполное замыкание контура из-за шума
3	5	6	Схожие изогнутые сегменты
7	8	6	Горизонтальная перекладина «8» vs штрих «7»

Все 8 наиболее частых ошибок относятся к парам кириллица цифра или визуально похожие глифы. Это объясняется тем, что EasyOCR обучался на общем корпусе текстов, где кириллические и латинские буквы встречаются гораздо реже в соседстве с цифрами. Специализированные CRNN-модели для номеров (например, LPRNet) дообучаются именно на таких парах и показывают $CRR > 0.97$ на аналогичных реальных данных.

Анализ причин разрыва синтетика/реальные данные. Разница в Plate Acc составляет $0.800 - 0.225 = 0.575$, в CRR — $0.975 - 0.750 = 0.225$. Основные факторы деградации на реальных кропах:

- Угол съёмки: перспективное искажение сжимает символы, особенно боковые; детектор CRAFT хуже локализует границы символов;
- Разрешение: при расстоянии > 15 м кроп номера содержит менее 80 пикселей в ширину против 200–300 пикселей на эталонных синтетических изображениях;
- Освещение и блики: засветка рефлектирующих пластин в ярком солнечном свете или ночью при фарах встречного транспорта частично скрывает контуры символов.

3.5.5 Анализ узких мест и практические рекомендации

Узкое место — EasyOCR ($>90\%$ латентности). EasyOCR выполняет два прохода по изображению (CRAFT для детекции символьных регионов + CRNN+CTC для декодирования строки) на CPU, что и объясняет задержку 350–500 мс. Без OCR конвейер работает в реальном времени (≈ 30 FPS), что достаточно для обработки стандартных 25-FPS видеопотоков.

Влияние разрешения номерного знака. EasyOCR наиболее чувствителен к разрешению кропа номерного знака. При разрешении входного кадра 1080p кроп номера содержит $\approx 200\text{--}300$ пикселей в ширину, что обеспечивает $\text{CRR} = 0.975$. При разрешении ниже 720p качество OCR существенно снижается — это типичная проблема для камер с низким разрешением.

Стратегии ускорения OCR:

1. Замена EasyOCR на CRNN, оптимизированный для российских номеров — даст $\approx 5\text{--}10\times$ ускорение;
2. Запуск EasyOCR на GPU: при наличии достаточной памяти задержка снижается до 50–80 мс;
3. OCR только для «ключевых» кадров (1 из N) при обработке видеопотока с агрегацией результатов.

Качественный результат на тестовом изображении. Для Toyota Camry 2011 конвейер корректно предсказал: цвет — silver, тип кузова — sedan. Это соответствует истинным характеристикам автомобиля и подтверждает работоспособность конвейера в режиме end-to-end.

В ходе выпускной квалификационной работы достигнута поставленная цель — разработана система автоматического определения характеристик транспортных средств (номерной знак, цвет кузова, тип кузова) по видеопотоку с камер наблюдения. Все шесть задач, сформулированных во введении, выполнены: проведён анализ существующих методов детекции и классификации, обоснован выбор архитектур, подготовлены датасеты, обучены и оценены модели, реализован единый конвейер обработки видео, проведён сравнительный эксперимент ResNet18 vs MobileNetV2. Основные результаты приведены ниже.

1. Архитектурный выбор. Комбинация YOLOv8n + ResNet18 + EasyOCR обеспечивает приемлемый баланс точности и скорости (см. таблицу 3.11).
2. Детектор номерных знаков. Fine-tuning YOLOv8n на датасете Russian license plates (Kaggle, 668 изображений, 50 эпох, batch=16, SGD, lr=0.01) позволил достичь $mAP@0.50 = 0.9554$. Дообученный на тех же данных YOLO26n превзошёл результат, достигнув $mAP@0.50 = 0.9669$, и был выбран финальной моделью-детектором. Медианный IoU = 0.809 и доля боксов с $IoU \geq 0.50$ в 94.0 % подтверждают высокую точность локализации. Это подтверждает высокую эффективность transfer learning при ограниченном объёме целевых данных.
3. Классификация цвета. ResNet18, дообученный на VCoR за 20 эпох с двухфазной стратегией, достигает Accuracy top-1 = 0.922 и top-3 = 0.994. Наиболее сложными классами оказались orange (F1 = 0.836) и silver (F1 = 0.847) из-за визуального сходства с соседними цветами при разном освещении. Результат превосходит кластеризационные методы на 7–12 % (таблица 1.4).
4. Классификация типа кузова. ResNet18 достигает Accuracy top-1 = 0.786. Сравнение с MobileNetV2 (таблица 3.9) показывает, что ResNet18 превосходит MobileNetV2 на 16.6 п.п. по точности при более высоком FPS на GPU T4 (299.4 против 169.0), что обусловлено лучшей оптимизацией стандартных свёрток в CUDA по сравнению с depthwise-операциями MobileNetV2. Наиболее сложный класс — sedan (F1 = 0.664) из-за визуального сходства с хетчбэком.
5. OCR номерных знаков. На синтетических номерах EasyOCR обеспечивает Plate Acc = 0.800 и CRR = 0.975. На реальных кропах NOMEROFF-NET RU (200 изображений из 2845) Plate Acc = 0.225, CRR = 0.750. Анализ ошибок выявил основные пары путаниц: 00 (26 случаев), B8 (17), A4 (12), T7 (8), Y7 (8) — все являются визуально схожими символами. Разрыв между синтетикой и реальными данными обусловлен неидеальным освещением, ракурсом и разрешением номеров на улице.
6. Производительность конвейера. Блоки детекции и классификации на GPU T4 суммарно дают ≈ 30 FPS. Узкое место — EasyOCR (> 90 % от общего времени). Без OCR конвейер работает в реальном времени (таблица 3.10).
7. Ограничения системы. EasyOCR является узким местом конвейера. Для встроенных систем целесообразно рассмотреть специализированный лёгкий OCR-модуль.

Направления дальнейшего развития:

- замена EasyOCR на CRNN-детектор, оптимизированный для российских номеров;
- расширение классов цвета и типа кузова;
- адаптация к ночным условиям съёмки (low-light enhancement);
- квантизация и pruning для развёртывания на NVIDIA Jetson.

- [1] Абрамов А. А. Алгоритм распознавания номерных знаков в условиях плохого качества видео // КиберЛенинка, 2019.
- [2] A Survey of Automatic License Plate Recognition Systems // Sensors, 21(9):3028, 2021.
- [3] Laroca R., Severo E., Zanlorensi L. A. и др. A Robust Real-Time Automatic License Plate Recognition Based on the YOLO Detector // arXiv:1802.09567, 2018.
- [4] Laroca R. Automatic License Plate Recognition in Real-World Scenarios: PhD Thesis // Universidade Federal do Paraná, 2021.
- [5] Two decades of vehicle make and model recognition // Journal of King Saud University — CIS, 2024.
- [6] Siddiqui A., Mammeri A., Boukerche A. Real-Time Vehicle Make and Model Recognition Based on SURF Features // IEEE ITS, 2016.
- [7] Manzoor M. A., Morgan Y. Vehicle Make and Model Recognition Using Deep Learning // Machine Learning and Knowledge Extraction, 1(2):36, 2022.
- [8] Su H., Wu X., Chen S., Ji Q. Vehicle Color Recognition Using Convolutional Neural Network // IEEE ICIP, 2015.
- [9] Кубатин И. А. Алгоритм определения цвета автомобиля методом кластеризации k-средних // КиберЛенинка, 2019.
- [10] Zhang H., Cisse M., Dauphin Y. N., Lopez-Paz D. mixup: Beyond Empirical Risk Minimization // ICLR, 2018.